

肖亦聪

电子邮箱: yicong.xiao@u.nus.edu 手机: +86 18026919165

GitHub: <https://github.com/yxiaoaz> 领英: <https://www.linkedin.com/in/edwardxiao2001/>

教育经历

新加坡国立大学

2024 年 8 月 - 2026 年 2 月

计算机科学（人工智能方向） 硕士

- GPA: 4.9 / 5.0
- 院长嘉许名单成员（专业前 5%-10%）
- 相关课程：不确定性建模、神经网络与深度学习、多媒体计算理论、图机器学习、大数据技术

香港科技大学

2019 年 9 月 - 2024 年 1 月

计量金融与计算机科学 本科

- GPA: 3.6 / 4.3
- 院长嘉许名单成员
- 相关课程：机器学习、概率论、Python 编程与数据科学、时间序列分析、搜索引擎算法、面向对象程序设计

工作经历

Intact Financial (HK) Limited

2024 年 1 月 - 2024 年 5 月

数据科学实习生

- 与团队合作开发了一款针对保险文件的智能文档解析软件，从 word 或 PDF 格式的保险文件中提取非结构化数据，并根据业务逻辑进行数据清洗和加工，输出结构化的保单数据，减少了核保人员手动记录新保单的工作量。
- 设计并实现了一个针对保险文件的聚类与主题建模算法，能够根据文本布局和语义内容对大批量保险文件进行聚类，并通过每个类中所有文本的 TF-IDF 值、在文件中出现的位置等因素对于该类进行主题建模，提高了针对来自新市场的大批量未知文档的文本解析逻辑开发的效率。
- 对来自新市场的法语保险文件进行探索性数据分析，与核保部门持续对接沟通开发需求，使用 Python 开发了公司首个针对法语文件的文档解析和数据加工程序。
- 使用 Python 和 Jinja 开发了一个能够自动生成仿真保险文件数据的程序，实现了文档解析 AI 模型的高效测试与迭代。

中国电信（北京研究院）

2023 年 9 月 - 2023 年 12 月

算法实习生

- 研究针对法律文本的知识表征学习，对于摘要生成、实体链接等领域的自然语言模型进行复现、实验以及分析。
- 使用 PyTorch 和 Hugging Face 对大语言模型进行微调，在包括提示词工程（prompt engineering）、提示词微调（prompt tuning）等方面进行实验，使模型能够完成法律条款和案例记录等长文档的摘要生成任务，有效压缩冗长文档且保留关键信息。
- 开发了用于获取训练数据的 Python 程序，实现了法律文档的网络爬取、文本数据提取与预处理，并以层级结构存储处理后文本。
- 管理并协调了多个数据标注项目，针对多个模型训练任务设计标注指南并与标注人员保持沟通，确保了高质量训练数据的及时生成。

工作技能

- 沟通语言: 普通话、英语 (托福: 114 分)
- 编程语言: 熟练使用 Python、SQL、Java、C++
- 数据科学工具: 熟练使用 PyTorch 框架以及 NumPy、Pandas、Scikit-learn、OpenCV 等常用的 Python 模块
- 数据可视化: 熟练使用 PowerBI 以及 Python 的 Matplotlib、Seaborn 模块
- 大数据 & 数据存储: 熟练使用 AWS S3、Spark、Databricks、MongoDB 等大数据或数据库工具
- 开发工具: 具备 Scrum 敏捷开发模式下的工作经历，熟练使用 Git、GitHub、Data Version Control (DVC) 等版本控制工具或平台

荣誉奖项

- 冠军: 香港科技大学“Fintechstic”金融科技案例大赛（2020）
- 亚军: 香港科技大学区块链商业模式大赛（2020）